



Universidad EAFIT

NOVA
CELSIA

ENTREGABLE

Bananas en Pijamas

David Grisales Posada
Juan Esteban García Galvis
Juan Manuel Rodríguez Sánchez
Julian David Mejia Otalvaro

14 de abril de 2024

Índice

1. Fase 1: Análisis de la Problemática	2
1.1. Identificación del Problema	2
1.2. Necesidades y Expectativas	2
2. Fase 2: Análisis del Mercado	2
2.1. Investigación de Competidores	2
2.2. Revisión de Soluciones en Internet	2
2.3. Encuestas o Entrevistas de Mercado	2
3. Fase 3: Validación de la Solución	3
3.1. Descripción de la Solución Propuesta	3
3.2. Análisis Comparativo Interno	3
3.3. Estrategia de "Pensamiento de Diseño"	3
4. Fase 4: Prototipo (MVP)	4
4.1. Diseño del Prototipo	4
4.2. Desarrollo e Implementación	6
4.3. Evaluación Interna del Prototipo	8
4.4. Plan de Mejora	9
5. Reflexión final	10

Índice de figuras

1. Diseño prototipo 1	4
2. Diseño prototipo 2	5
3. Diseño prototipo 3	5
4. Mockup 1	7
5. Mockup 2	8
6. Mockup 3	8
7. Salida	9

1. Fase 1: Análisis de la Problemática

1.1. Identificación del Problema

La desagregación es una parte importante hacia el paso a la optimización en el uso de la energía. El problema es que la medición intrusiva es compleja ya que condiciona al usuario al uso de sus enchufes y limita a la empresa de que el usuario cumpla con las indicaciones dadas sobre el uso de los enchufes. Por eso se hace necesario emplear soluciones tecnológicas que permitan deducir el valor de consumo de un usuario dados una hora del día y el consumo total en ese momento, todo basado en los históricos de uso de los dispositivos electrónicos del cliente (unos tres meses de generación de históricos base). La idea es restringir la solución a una búsqueda intrusiva mínima.

1.2. Necesidades y Expectativas

La necesidad principal es la de conocer el uso de cada electrodoméstico a lo largo de los minutos del día. Las expectativas que se tienen es que se pueda realizar sin un permanente monitoreo intrusivo. Para lo cual se propone una solución de software que reciba los históricos y pueda hacer predicciones a futuro. O alguna otra solución factible (de fácil implementación y costo considerable).

2. Fase 2: Análisis del Mercado

2.1. Investigación de Competidores

EPM: es una empresa que entre otros servicios públicos, provee el de energía eléctrica al 94,2 % de Antioquia y representa al 26,6 % de generadores en el país con 2400 GWh. Siendo EPM la más importante en generadores del país. Isagen: es la segunda mayor generadora de energía eléctrica del país cubriendo el 23.8 % del mercado en Colombia. Tiene 19 centrales en todo el país ubicadas en Tolima, Santander, La Guajira, Meta y Caldas, lo que completa un valor de 18300GWh.

2.2. Revisión de Soluciones en Internet

Implementación de inteligencia artificial, Smarkia, una empresa especializada en la energía eléctrica ha creado un modelo de deducción de valores de consumo tomando el total del consumo y datos de entrenamiento del modelo. Hasta ahora Celsia ha usado el uso de medidores en cada dispositivo, no es la solución que esperan implementar todo el tiempo, pero hasta ahora hay una solución usada.

2.3. Encuestas o Entrevistas de Mercado

En lo que se tiene, se ha indicado que la desagregación de cargas beneficiaría en manera positiva a los usuarios ya permitiría generar ofertas y planes de energía personalizados y adaptados a cada cliente. Reducción de costes ya que permite gestionar mejor la energía para los momentos de picos y para los momentos en que se usa menos la energía. Respecto a los clientes permite que éstos gestionen mejor sus patrones de consumo y puedan optimizar el uso y de esta forma ahorrar energía. Permite mantener un control para detectar fraudes o robos de energía cuando se detectan patrones de consumo inusuales.

3. Fase 3: Validación de la Solución

3.1. Descripción de la Solución Propuesta

La solución propuesta fue entrenar un modelo de Machine Learning para que aprendiera a predecir los valores de consumo basado en los históricos de cada cliente. Para esto se hace necesario implementar una herramienta que lea y que procese los archivos .csv, por ejemplo Python y R.

3.2. Análisis Comparativo Interno

Objetivo: Evaluar el rendimiento y la eficacia de nuestro modelo de predicción para la Desagregación de Cargas en comparación con métodos internos anteriores.

Métodos: Revisión y comparación de resultados obtenidos por nuestro modelo actual con modelos internos anteriores en términos de precisión, escalabilidad, usabilidad y tiempo de procesamiento.

Resultados:

- Mayor precisión en la predicción de cargas eléctricas.
- Mejora en escalabilidad y eficiencia en el procesamiento de datos.
- Interfaz de usuario más intuitiva y fácil de usar.
- Tiempo de procesamiento más rápido en comparación con modelos anteriores.

Conclusiones: Nuestro modelo actual representa una mejora significativa en términos de precisión, escalabilidad, usabilidad y eficiencia en comparación con los modelos internos anteriores, respaldando su adopción y continuación en futuras predicciones de cargas eléctricas.

3.3. Estrategia de "Pensamiento de Diseño"

La principal estrategia de diseño fue el esencialismo, tratamos de implementar la cantidad necesaria de funciones para que el usuario pudiera acceder a sus históricos de uso de la energía, para esto se tiene un botón grande y central para subir el archivo .csv del consumo. Luego de eso, se incluye la función de ver históricos por meses y con valor por defecto del último mes para tener en cuenta esos valores para una mejor gestión y control.

4. Fase 4: Prototipo (MVP)

4.1. Diseño del Prototipo

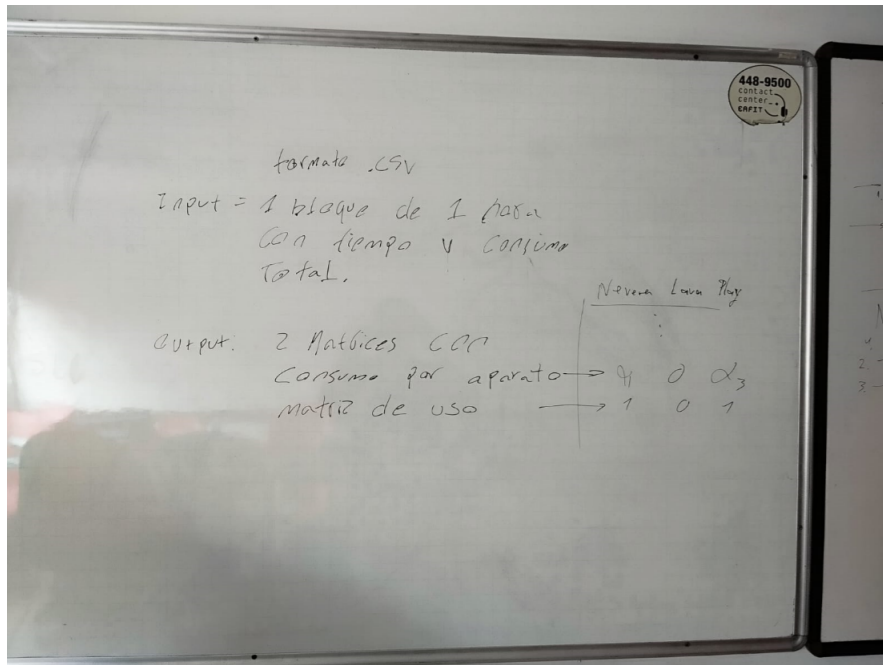


Figura 1: Diseño prototipo 1

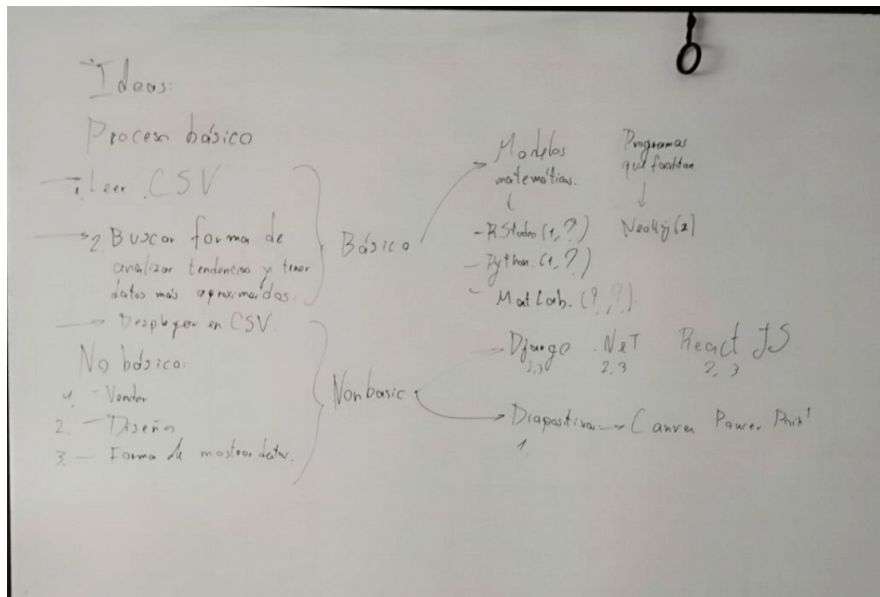


Figura 2: Diseño prototipo 2




Figura 3: Diseño prototipo 3

El diseño del prototipo de nuestro modelo predictivo se centra en desarrollar una herramienta eficaz para predecir el consumo de energía de ciertos electrodomésticos en la casa y si uno de estos está prendido del respectivo domicilio. Para lograr este objetivo, estamos seleccionando cuidadosamente las características relevantes que servirán como entradas para nuestro modelo, incluyendo el total de watts, el tiempo y si el equipo está prendido o no. Utilizaremos algoritmos de aprendizaje automático como regresión lineal para construir el modelo predictivo, y

realizaremos preprocesamiento de datos, como limpieza y normalización, antes de entrenar el modelo.

4.2. Desarrollo e Implementación

```
import pandas as pd
import numpy as np
from sklearn.linear_model import LinearRegression
from tkinter import Tk, filedialog
from datetime import datetime

def convertir_a_minutos(hora):
    horas, minutos = map(int, hora.split(':'))
    return horas * 60 + minutos

def cargar_archivo():
    root = Tk()
    root.withdraw()
    archivo = filedialog.askopenfilename(filetypes=[("CSV files", "*.csv")])
    return archivo

df = pd.read_csv("consumo_casa2.csv")
df['Fecha'] = df['Fecha'].apply(lambda x: x.split()[1])
df['Fecha'] = df['Fecha'].apply(convertir_a_minutos)

X = df[['Fecha', 'Medidor [W]']].values
Y = df[['Refrigerator', 'Clothes washer', 'Clothes Iron', 'Computer', 'Oven', 'Play', 'TV', 'Sound system']].values

X_train = X[:-1]
Y_train = Y[:-1]

model = LinearRegression()
model.fit(X_train, Y_train)

archivo_prediccion = cargar_archivo()
df_prediccion = pd.read_csv(archivo_prediccion)
df_prediccion['Fecha'] = df_prediccion['Fecha'].apply(lambda x: x.split()[1])
df_prediccion['Fecha'] = df_prediccion['Fecha'].apply(convertir_a_minutos)
X_pred = df_prediccion[['Fecha', 'Medidor [W]']].values

y_pred = model.predict(X_pred)

# Ajustar los valores negativos a 0
y_pred = np.maximum(y_pred, 0)

df_resultado = pd.DataFrame(y_pred, columns=['Refrigerator', 'Clothes washer', 'Clothes Iron', 'Computer', 'Oven', 'Play', 'TV', 'Sound system'])

# Redondear los valores a 2 decimales
df_resultado = df_resultado.round(decimals=2)
```

```
print("Predicciones para los últimos datos del archivo seleccionado:")
print(df_resultado)

score = model.score(X_train, Y_train)
print("Score del modelo:", score)

# Permitir al usuario seleccionar dónde guardar el resultado
guardar_resultado = filedialog.asksaveasfilename(defaultextension=".csv", filetypes=[("CSV files", ".csv")])

if guardar_resultado:
    df_resultado.to_csv(guardar_resultado, index=False)
    print("Resultado guardado en:", guardar_resultado)
else:
    print("No se seleccionó ningún archivo para guardar el resultado.")
```

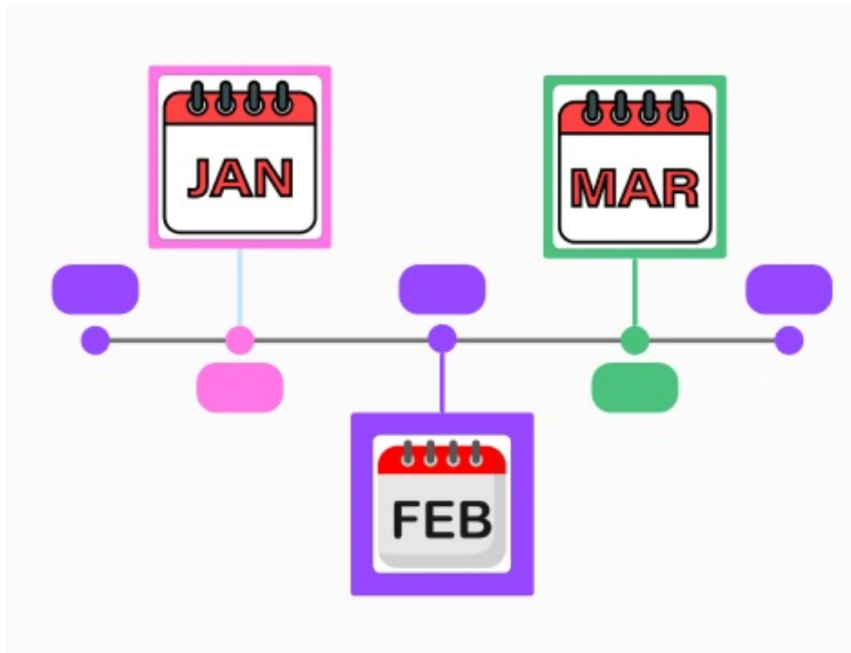


Figura 4: Mockup 1




Figura 5: Mockup 2

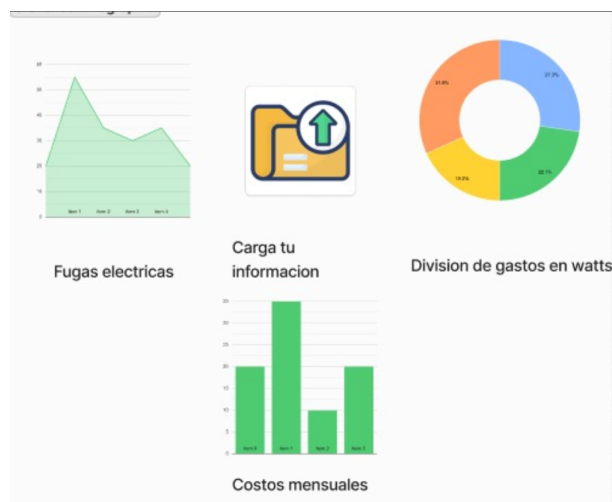


Figura 6: Mockup 3

4.3. Evaluación Interna del Prototipo

Hemos llevado a cabo una evaluación interna del prototipo de nuestro modelo de predicción para la Desagregación de Cargas en nuestra empresa de energía. Durante este proceso, hemos validado la precisión del modelo, identificado áreas de mejora en el algoritmo y la interfaz de usuario, y recopilado retroalimentación del equipo de desarrollo y otros miembros del equipo interno. Basándonos en estos resultados, estamos realizando ajustes y mejoras en el prototipo antes de pasar a una evaluación externa con usuarios finales.

```
0      69.18      7.42      21.91      1.44  40.64  0.55  2.41      3.57
1      69.90      7.52      22.54      1.45  41.92  0.56  2.50      3.57
2      69.71      7.49      22.35      1.44  41.54  0.56  2.49      3.57
3      69.93      7.52      22.55      1.45  41.93  0.56  2.52      3.57
4      59.50      6.05      13.31      1.38  23.25  0.50  1.46      3.55
...      ...      ...      ...      ...      ...      ...      ...
194118  44.85      2.07      0.00      1.30  0.00  1.22  15.17      3.47
194119  44.39      2.00      0.00      1.30  0.00  1.22  15.14      3.47
194120  44.25      1.98      0.00      1.30  0.00  1.22  15.13      3.47
194121  44.72      2.05      0.00      1.30  0.00  1.22  15.19      3.47
194122  44.56      2.02      0.00      1.30  0.00  1.22  15.18      3.47

[194123 rows x 8 columns]
Score del modelo: 0.13649762808803245
```

Figura 7: Salida

4.4. Plan de Mejora

Objetivos:

1. Mejorar la precisión del modelo de predicción.
2. Optimizar la usabilidad de la interfaz de usuario.
3. Implementar funcionalidades adicionales según las necesidades de los usuarios.

Estrategias:

1. Refinar el algoritmo de predicción mediante análisis detallados de datos y retroalimentación del equipo.
2. Optimizar la interfaz de usuario a través de pruebas de usabilidad y rediseño basado en feedback.
3. Desarrollar funcionalidades adicionales prioritarias según el feedback de los usuarios y los requisitos del negocio.

Plan de Acción:

1. Asignar recursos para análisis de datos y desarrollo de modelos.
2. Formar un equipo dedicado al diseño de la interfaz y la experiencia del usuario.
3. Priorizar y desarrollar funcionalidades adicionales basadas en su impacto y viabilidad técnica.

Seguimiento y Evaluación:

1. Realizar revisiones periódicas del progreso del proyecto.
2. Recopilar feedback continuo del equipo y usuarios finales.
3. Ajustar el plan según sea necesario para garantizar el éxito del proyecto.

5. Reflexión final

A través de nuestra experiencia en el hackathon, aprendimos mucho sobre el trabajo en equipo, la resolución de problemas y el uso de modelos predictivos en el sector energético.

Aprendizajes:

Nuestra experiencia de aprendizaje más importante fue la importancia del trabajo en equipo y la comunicación efectiva. Nos dimos cuenta de que cada miembro de nuestro equipo tenía habilidades y conocimientos únicos y que combinarlos nos permitía resolver problemas de manera más efectiva. También aprendimos cómo aplicar conocimientos teóricos sobre modelos predictivos a situaciones del mundo real, lo que nos ayudó a comprender mejor estos conceptos.

Desafíos:

Durante el hackathon, enfrentamos varios desafíos. El primero fue comprender completamente los datos proporcionados por la empresa de servicios públicos y el problema. Tuvimos que investigar y aprender sobre el sector energético para interpretar correctamente los datos y desarrollar modelos de previsión adecuados. Otro desafío fue el tiempo limitado para completar el proyecto. Esto nos permitió trabajar de manera eficiente y tomar decisiones rápidas.

Futuro

Si tuviera que hacer algo diferente en el futuro, me prepararía mejor para el hackathon. Esto puede incluir realizar más investigaciones en el sector energético y aprender sobre diferentes técnicas de modelado predictivo. Además, queremos mejorar nuestras habilidades de gestión del tiempo para afrontar de forma más eficaz los retos que surgen al trabajar bajo presión. . En general, el hackathon fue una experiencia valiosa que me permitió crecer personal y profesionalmente. Esto nos ayudó a mejorar nuestras habilidades técnicas, aprender a trabajar en equipo y comprender la importancia de adaptarnos y resolver problemas del mundo real.

Referencias

- [1] Müller, Andreas C., and Sarah Guido. *Introduction to Machine Learning with Python: A Guide for Data Scientists*. O'Reilly Media, Inc., 2016.